

1. Sieć Hopfielda

1.1 Sieci ze sprzężeniem zwrotnym

Sieci ze sprzężeniem zwrotnym tworzą odrębną grupę sieci neuronowych, występującą również pod nazwą sieci rekurencyjnych bądź asocjacyjnych. Zamknięcie pętli sprzężenia zwrotnego powoduje, iż sieć staje się dynamiczna. Sygnały na jej wyjściach zależą zarówno od aktualnego stanu wejść, jak i od poprzednich sygnałów wejściowych, które są z kolei uzależnione od poprzednich sygnałów wejściowych. Można zatem stwierdzić, że sygnały na wyjściach sieci zależą od stanu początkowego oraz działających pobudzeń.

Do cech wspólnych sieci rekurencyjnych należy fakt, iż istnieją symetryczne powiązania między neuronami. Neurony w tych sieciach nie tworzą wyraźnych warstw i mogą być rozważane w dowolnej topografii.

Wyróżnić należy następujące sieci rekurencyjne: sieć Hopfielda, jej uogólnienie – sieć BAM, sieć Hamminga oraz sieci rezonansowe.

1.2 Charakterystyka sieci Hopfielda

Sieć Hopfielda jest jednym z przedstawicieli sieci ze sprzężeniem zwrotnym. Nazwa pochodzi od nazwiska twórcy, J. J. Hopfield'a, który w roku 1982 przedstawił model tejże sieci. Publikacja Hopfield'a, w której zdefiniował sieć stała się punktem zwrotnym w badaniach nad sieciami neuronowymi. Należy do najbardziej popularnych sieci neuronowych. Ważną jej cechą jest prosty sposób uczenia oraz łatwość implementacji w postaci układu fizycznego.

W sieci tej charakterystyki neuronów są nieliniowe:

$$y_m^{(j)} = \varphi(e_m^{(j)}),$$


gdzie

$$e_m^{(j)} = \sum_i w_i^{(m)} y_i^{(j)} + x_m^{(j)},$$

a nieliniowość $y = \varphi(e)$ jest postaci:

$$y_m^{(j+1)} = \begin{cases} 1 & \text{dla } e_m^{(j)} > w_0^{(m)} \\ y_m^{(j)} & \text{dla } e_m^{(j)} = w_0^{(m)} \\ -1 & \text{dla } e_m^{(j)} < w_0^{(m)} \end{cases}.$$

Istnieją w niej połączenia z warstw wyjściowych do warstw wcześniejszych, czyli sprzężenie zwrotne. Co za tym idzie możliwe jest pojawienie się przebiegów dynamicznych. Zacierą się w tych sieciach podział na warstwy, ponieważ każdy neuron sieci ma kontakt z odpowiadającym mu sygnałem wejściowym.



Rysunek 1 Model sieci Hopfielda

Wadą sieci Hopfielda jest jej mała pojemność, wyrażana małą ilością klas jakie sieć może zapamiętać.

1.3 Sieć Hopfielda jako pamięć autoasocjacyjna

Sieć Hopfielda może pracować jako pamięć autoasocjacyjna (skojarzeniowa), w takim przypadku jej zadaniem jest "zapamiętanie" wzorców tak aby po podaniu na wejście sieci sygnału $\mathbf{x}$ na jej wyjściu ustalił się wektorowy sygnał $\mathbf{y}_{ust}$ odpowiadający jednemu z wzorców. Odtworzony wzorzec powinien być ponadto "najbliższy" wektorowi $\mathbf{x}$. Jako miarę odległości pomiędzy wektorami $\mathbf{x}$ i $\mathbf{y}_{ust}$ przyjmuje się miarę Hamminga definiowaną następująco:

$$\|\mathbf{x} - \mathbf{y}_{ust}\| = \frac{1}{2} \sum_{i=1}^N |x_i - y_{ust\ i}|$$

gdzie indeks i oznacza i -tą składową wektora.

Inaczej mówiąc, sieć Hopfielda wykorzystywana jako pamięć skojarzeniowa powinna na podstawie danych wejściowych, które w większości przypadków są zakłócone "odtworzyć" najbliższy zapamiętany wzorzec. W celu uzyskania takiego rezultatu, na etapie uczenia sieci, należy zapewnić dobór odpowiednich wag.

1.4 Stabilność

W celu ułatwienia badania stabilności sieci Hopfielda została wprowadzona tzw. funkcja obliczeniowa zwana energią. Ciekawą własnością tej funkcji jest fakt, iż jej wartość w kolejnych iteracjach nie wzrasta. Kolejne stany są przyjmowane w kierunku przeciwnym do gradientu energii, aż do momentu osiągnięcia przez nią minimum lokalnego.

Energię wyrazić można następującym wzorem:

$$E = \frac{1}{2} \sum_{i=1}^M \sum_{j=1}^M w_{ij} y_i y_j - \sum_{i=1}^M y_i I_i$$

Przy czym I_i jest wejściowym prądem niezerównoważenia, o charakterze prądu pobudzenia.

Wymogiem stabilnego działania pamięci autoasocjacyjnej jest warunek, aby odpowiedź i -tego neuronu na l -ty wzorzec uczący $x^{(l)}$ była równa i -tej składowej tego wzorca $x_i^{(l)}$

$$y_i^{(l)} = \operatorname{sgn} \left(\sum_{j=0}^N w_{ij} x_j^{(l)} \right) = \operatorname{sgn} \left(\frac{1}{N} \sum_{j=0}^N \sum_{k=1}^P x_i^{(k)} x_j^{(k)} x_j^{(l)} \right) = x_i^{(l)}$$

Pamięć autoasocjacyjna ma właściwości korekcyjne. Przy prezentacji próbki różniącej się bitami na pewnych pozycjach wektora, sieć neuronowa może dokonać korekcji tych bitów i zakończyć proces klasyfikacji we właściwym atraktorze.

2. Metody uczenia sieci Hopfielda

2.1 Reguła Hebba

Regułę Hebba można zapisać w następujący sposób:

- Jeśli neurony A i B połączone synapsą są pobudzone jednocześnie (tj. synchronicznie) to połączenie synaptyczne je łączące jest wzmacniane.

- Jeśli neurony A i B połączone synapsą są pobudzone niejednocześnie (tj. asynchronicznie) to połączenie synaptyczne je łączące podlega osłabieniu.

Wagi synaptyczne między neuronami A i B modyfikowane są zgodnie ze wzorem:


$$w_{ij}(k+1) = w_{ij}(k) + \eta y_i(k) y_j(k), \text{ gdzie}$$

w_{ij} - waga połączenia między neuronami i oraz j

y_i - stan aktywacji neuronu i

y_j - stan aktywacji neuronu j

η - współczynnik uczenia



Rysunek 2 Połączenie między neuronami

Wzrost wag połączeń w regule Hebba jest nieograniczony, dlatego uczenie nie kończy się, to natomiast prowadzi do rozbieżności procesu.

2.2 Reguła Wzajemnych Ograniczeń

Ze względu na ograniczenia Metody Hebba zostały wprowadzone do niej pewne modyfikacje. Zawiera je Metoda Wzajemnych Ograniczeń. Reguła ta wprowadza składnik „odpychający”, który chroni przed rozbieżnością procesu uczenia.

Wagi w niej wylicza się według następującego wzoru:

$$w_{ij}(k+1) = w_{ij}(k)(1-\gamma) + \eta y_i(k)y_j(k)$$

γ - współczynnik zapominania

2.3 Reguła Rzutowania Delta

Reguła Delta jest najpopularniejszą i najchętniej stosowaną metodą uczenia z nauczycielem. Z Metodą Największego Spadku (Regułą Delta) mamy do czynienia, gdy uaktualnianie wag następuje każdorazowo po prezentacji jednej pary uczącej. Reguła Delta jest uogólnieniem Reguły Perceptronu. Stosowana jest dla neuronów o ciągłej funkcji aktywacji. Wagi w niej uzyskuje się na podstawie poniższej zależności:

$$w_{ij}(k+1) = w_{ij}(k) + c(d_i - y_i)f(net_i)x$$

2.4 Zmodyfikowana Reguła Perceptronu

W przypadku skokowych funkcji aktywacji z jakimi mamy do czynienia w przypadku sieci Hopfielda można stosować Regułę Perceptronu (rys.) bądź jej uogólnienie znane pod nazwą Reguły Widrowa - Hoffa.

Regułę Perceptronu można sformułować w następujący sposób:

Przy wstępnie ustalonych wartościach wag w_{ij} prezentuje się na wejściu wektor uczący x i oblicza wartość sygnału wyjściowego y_i . W wyniku porównania aktualnej wartości y_i oraz wartości żądanej d_i dokonuje się aktualizacji wag zgodnie z zależnością

$$w_{ij}(k+1) = \begin{cases} w_{ij}(k), & \text{dla } y_i = d_i \\ w_{ij}(k) + x_j, & \text{dla } y_i = 0, \quad d_i = 1 \\ w_{ij}(k) - x_j, & \text{dla } y_i = 1, \quad d_i = 0 \end{cases}$$

Po uaktualnieniu wag następuje prezentacja nowego wektora uczącego i skojarzonej z nią wartości zadanej d_i , a następnie ponownie aktualizuje się wagi. Proces powtarzany jest na wszystkich próbkach uczących wielokrotnie, aż uzyska się minimalizację różnic między wszystkimi wartościami wyjściowymi i odpowiadającymi jej wartościami zadanymi.

3. Program Snhop jako symulator do rozpoznawania znaków

3.1 Wprowadzenie do programu – wymagania

Symulator Snhop powstał jako integralna część pracy dyplomowej: *Rozpoznawanie obrazów przy użyciu symulatora sieci Hopfielda*. Został zaimplementowany dla środowiska Sun Java 2.

Pozwala na przetestowanie różnych metod uczenia sieci Hopfielda oraz ocenienie skuteczności tychże metod w rozpoznawaniu znaków.


Do podstawowych właściwości programu należą: możliwość ustalenia rozmiaru obrazu, ustawienie parametru BIAS. Symulator pozwala na wybór metody uczenia oraz ustawienie parametrów tej metody, zapisanie całej sieci bądź też poszczególnych zbiorów: wzorcowego, testującego oraz wynikowego. Po zakończonym etapie uczenia i rozpoznawania program generuje raport.

Minimalne wymagania programu do prawidłowego działania to:

- Procesor 200MHz
- RAM 64MB
- Sun J2RE 1.3.1

3.2 Instrukcja obsługi programu Snhop

W oknie głównym programu mamy cztery zakładki: instrukcja, parametry, symulacja oraz wyniki. W Instrukcji znajdujemy wszystkie potrzebne wskazówki dotyczące programu oraz pracy z nim. Zakładka Parametry służy nam do wybrania interesujących nas ustawień programu.




Rysunek 3 Okno wyboru parametrów

W tym miejscu wybieramy metodę uczenia sieci oraz parametry wykorzystywane podczas rozpoznawania.

Kolejna zakładka, którą jest Symulacja pozwala nam na wczytanie zbioru uczącego, testującego, a także zapoznanie się z otrzymanymi wynikami. Po rozpoznaniu przez sieć wzorca mamy możliwość wygenerować raport, który następnie możemy obejrzeć po przejściu do zakładki Wyniki (Dokładne scany zakładki Symulacja jak i Wyniki zostaną przedstawione w rozdziale 5. Eksperymenty, testy, próby).

Funkcje symulatora uruchamiamy z paska **Menu**, wyjątkiem jest jedynie komenda **Uczenie i Rozpoznawanie** dostępne wyłącznie z paska **Narzędzi**.



Rysunek 4 Pasek Menu i Pasek Narzędzi

4. Bibliografia

[1] Mancar M. *Rozpoznawanie obrazów przy użyciu symulatora sieci Hopfielda*, praca dyplomowa pod kierownictwem dr inż. Jolanty Grabskiej-Chrząstowskiej, Kraków, 2002

[2] Grabska-Chrząstowska J., Mancar M. *Odtwarzanie zniekształconych znaków przy pomocy sieci Hopfielda*, Kraków

[3] Grabska-Chrząstowska J. *Optymalizacja sieci Hopfielda przy konstrukcji pamięci skojarzeniowych*, Kraków

[4] Tadeusiewicz R. *Sieci neuronowe*, Akademicka Oficyna Wydawnicza RM, Warszawa, 1993